数据结构常见模型及应用

2024年7月

feecle8146

回顾

回顾

昨天我们学习了树状数组、倍增、dfs 序三个主要技巧。试着回忆一下:

- 1. 树状数组的循环不变式是什么?
- 2. 树状数组如何维护区间加区间求和?如何拓展到二维?
- 3. 如何设计倍增信息?
- 4. dfs 序的作用是什么? 如何使用 dfs 序维护到根加子树求和?

今天, 我们将学习几个常见模型, 在模型中运用之前学习的数据结构。

单调栈

单调栈的结构

单调栈回答了如下的问题: 给定一个序列 a。对于每个 $1 \le i \le n$,维护出 a[1...i] 这个前缀的所有后缀最大值的信息。

思考: a[1...i] 的后缀最大值相比于 a[1...i-1] 的后缀最大值怎么改变?

只有≤ a_i (被 a_i 比下去的)会改变。

据此可以写出下面的代码:

```
st[0] = top = 0; // 特别是多次单调栈不能忘!
for (int i = 1; i <= n; i++) {
    while (top && a[i] >= a[st[top]]) top--;
    st[++top] = i;
    // 此时 st 就存储了 [1..i] 的后缀最大值下标
}
```

单调栈的结构

练习:

- 1. 证明前述代码时间复杂度为 O(n)。
- 2. 右侧代码的时间复杂度?

```
for (int i = 1; i <= n; i++) {
    while (top && a[i] >= a[st[top]]) top--;
    st[++top] = i;
    for (int j = 1; j <= top; j++) {
        printf("%d\n", st[j]);
    }
}</pre>
```

由于所有前缀的所有后缀就是所有区间,所以我们已经获得了所有区间的最值信息,可惜不是显式的(或者说可枚举的)。

感兴趣的同学可以课后自学"笛卡尔树"。

区间最大值

无来源

给你一个数组,多次询问区间最大值。

要求用单调栈解决。

单调栈在扫到 i 的时候, 我们就获知了 [1 ... i] 的所有后缀的最大值信息, 也就是右端点为 i 的所有区间的答案。

然而,扫到i+1的时候,单调栈就改变了。所以,只有扫到i这个时刻,才能回答[...,i]的询问。由此,你能想到解决办法吗?

离线询问,将询问 [l,r] 放进r 的 vector 里。对询问 [l,r],在单调栈上二分出最小的 $\geq l$ 的后缀最大值。

区间最大值之和

无来源

给你一个数组, 求所有区间[l,r]的最大值之和。

要求线性。

单调栈在扫到 i 的时候, 我们就获知了 [1 ... i] 的所有后缀的最大值信息。

[1...i] 所有后缀的最大值之和是多少?

$$\sum_{i} a_{st_i} \times (st_i - st_{i-1})$$

可以在单调栈上维护前缀和。本做法其实对所有前缀 α[1...i] 都求了答案。

单调栈

区间后缀最大值和

无来源

给你一个数组,多次询问区间的所有后缀的最大值之和。

 $n, q \le 300000$

单调栈在扫到 i 的时候, 我们就获知了 [1 ... i] 的所有后缀的最大值信息, 也就是右端点为 i 的所有区间的答案。

结合预处理的 $\sum_{i} a_{st_i} \times (st_i - st_{i-1})$, 只需找出 l 在 st 上的分界点 $(st_i < l \leq st_{i+1})$, 特殊处理一下 j 这一段, 其它的就是前缀和相减。

单调栈

prev

无来源

给你一个数组,对于每个i,求最大的j < i使得 $a_j > a_i$ 。

要求线性。

就是i处单调栈(还没把i加进去时)的栈顶。

据此,能否用另一种方法解决前一题?

还可以类比:实数区间覆盖,只能用半开半闭区间才不重不漏。

记本题答案为 l_i ,从右往左的答案为 r_i 。i 作为区间最小值,几乎等价于 $l \in (l_i, i], r \in [i, r_i)$,但 l_i, r_i 需要一个取等一个不取等!为了理解红色部分,可以考虑a = [1,1,1] 的情况。

带删数的区间最大值之和

CF1988E

定义数组a所有区间的最大值之和为f(a)。

设a删掉第i个元素得到的数组为 b_i ,求所有 $f(b_i)$ 。

如何将上述问题的做法泛化到本题?

提示:枚举最小值位置j,考虑j对哪些 b_i 有贡献。

分i所在区间(与 l_i , r_i 位置关系)讨论,用差分计算答案。

体育馆问题

CF1601E

有一个体育馆,第 $i(1 \le i \le n)$ 天,票价为 a_i 元。每张你手上的票可以管任意连续的k(定值)天,也就是说,如果你在第i 天买了这张票,你可以任意选择A,满足 $i \le A$,这样,第A,A+1,...,A+k-1 天都可以用这张票进入体育馆。

q次询问,每次给出 l,r,问如果第 l 天某人来到这个城市(也就是无法在第 l 天前买票),并且要在第 l,l+1,...,r 天进入体育馆,至少要花多少钱。 $n,q \leq 300000$

提示: 先形式化地写出问题。

体育馆问题

CF1601E

$$\sum_{i \in \mathbb{N}} [l + ik \le r] \min_{l \le j \le l + ik} a_j$$

注意到最小值的计算除了第一天 a_l ,都是k个k个一组的。同时,不妨设l,r模k同余。

 $\min_{l \leq j \leq l+ik} a_j$ 可以写成 $\min(a_l, b_{l+k}, ..., b_{l+ik})$,其中 $b_i = \min_{i-k < j \leq i} a_j$ 。可以用单调队列 O(n) 求出 b。

思考:此时能否再简化问题?

提示:发现独立性。

体育馆问题

CF1601E

$$\sum_{i \in \mathbb{N}} [l + ik \le r] \min_{l \le j \le l + ik} a_j$$

发现独立性。

注意到模k不同余的a,b对询问互不影响,所以可以分开处理每种模k的余数。

分开处理后,即为:给定一个序列,区间询问区间每个位置的 min(区间前缀最小值, v) 之和。

在单调栈上二分,找到 min 的分界点,前缀和回答。

小结

单调栈的学习中, 需要注意的要点有:

- 1. 理解单调栈维护的是什么: a[1...i]的所有后缀最值。
- 2. 理解l,r数组的用途。当需要对所有区间的最值进行操作时,枚举最值i并考察 l_i,r_i 是常见的做法。 特别地,理解区间最大值之和l,r需要一边取等一边不取等。
- 3. 理解单调栈上前缀和、二分是如何解决区间询问问题。

感兴趣的同学可以课后自学"笛卡尔树"。

序列分治

序列分治梗概

分治是一个很大的话题,涵盖了广泛的算法设计思想。今天我们主要讲序列分治。

如果有一个问题需要对所有 $1 \le l \le r \le n$ 的每一对 (l,r), 求它们整体的结果(例如区间最大值之和), 就可以使用序列分治。

通常情况下,序列分治算法流程为:定义 Solve(L, R) 表示求出 $L \le l \le r \le R$ 的整体结果。令 $mid = \frac{L+R}{2}$ (取中点目的是减少递归层数),先求出 $L \le l \le mid$, $mid < r \le R$ 的整体结果,再调用 Solve(L, mid) 和 Solve(mid+1, r)。

序列分治和线段树

你也许已经发现, 序列分治的划分方式和线段树类似。

思考:两者有没有其它共同之处?

(l,r) 的贡献被计算的 [L,R] 其实就是在线段树上查询 [l,r] 时,斜体部分同时满足的最浅结点!

```
int Sum(int p, int 1, int r, int x, int y) {
    if (x <= 1 && r <= y) return sum[p];
    int mid = (1 + r) >> 1, res = 0;
    if (x <= mid) res += Sum(p * 2, l, mid, x, y);
    if (mid < y) res += Sum(p * 2 + 1, mid + 1, r, x, y);
    return res;
}</pre>
```

序列分治

分治的目的

为什么分治能简化问题?

- 1. 原来的限制 l < r 简化成了 $l \in A, r \in B$ 。
- 2. 对于与序列的区间 [l,r] 相关的问题, 左右两边可能具有独立性, 且只需要在最后进行一次信息合并。相对地, 线段树就需要 log n 次。
- 3. 对于与序列的区间 [l,r] 的所有子区间 [l',r'] 相关的问题,将问题 拆成了一个前缀、一个后缀和跨过的部分。前缀和后缀比区间简单,而跨过的就去掉了 $l' \leq r'$ 的限制。

序列分治

逆序对

经典问题

求一个排列的逆序对数。

就是求有多少对(i,j)满足i < j且 $a_i > a_j$ 。

分治后,问题变为:有多少对 $a_i \in S, a_j \in T$ 满足 $a_i > a_j$ 。

可以分别排序后再双指针。

你或许已经发现了,该过程和归并排序求逆序对的过程本质上是一样的。不过,与这里所讲相比,归并排序巧妙利用分治结构直接进行了排序,在朴素分治基础上优化了一个log。

序列分治

区间最大子段和

经典问题

给定一个序列, 多次询问区间最大子段和。

分治,在 $l \in [L, mid], r \in [mid + 1, R]$ 的时候处理询问 [l, r]。实现可以递归传一个vector,其中包含所有还未解决且被当前区间包含的询问。这也是分治解决区间询问问题的一般方法。

对于询问 (l,r), 答案就是 $\max\{[L,mid]$ 后缀最大子段和, [mid+1,R]前缀最大子段和, [L,mid]最大后缀和 + [mid+1,R]最大前缀和}, 这三项都可以在分支过程中扫描得出。

思考: 时间复杂度?

$$O((n+q)\log n)$$

序列分治



P6240

给定一个序列,每个元素是物品,具有体积 w_i 和价值 c_i 。 q次询问,每次询问一个区间 [l,r] 和背包大小V,请你求出用这个背包去装区间内的物品(每个物品只能装一次),价值和最大是多少。

$$n \le 10^4, q \le 10^5, V \le 500$$

分治, 在 l ∈ [L, mid], r ∈ [mid + 1, R] 的时候处理询问 [l, r]。具体如何处理?

对于询问 (l,r), 答案就是 [l,r] 区间背包的一项, 可以由左侧后缀背包和右侧前缀背包 O(V) 合并而来。

序列分治



P6240

给定一个序列,每个元素是物品,具有体积 w_i 和价值 c_i 。 q次询问,每次询问一个区间 [l,r] 和背包大小V,请你求出用这个背包去装区间内的物品(每个物品只能装一次),价值和最大是多少。

$$n \le 10^4$$
, $q \le 10^5$, $V \le 500$

思考:

1. 上述算法的时间复杂度?

$$O(nV\log n + qV + q\log n)$$

2. 本题中分治和线段树相比体现了什么特点? 只需一次合并的一项,而线段树需 log 次合并的 O(V) 项

序列分治

Special Segments

CF1156E

给定一个数组,问有多少个
$$(i,j)$$
 满足 $a_i + a_j = \max_{k \in [i,j]} a_k$ 。 $n \le 10^5$

先分治, 假设 $i \in [l, mid]$, $j \in (mid, r]$ 。

预处理左边后缀 \max 数组 c 和右边前缀 \max 数组 d,问题化为

$$a_i + a_j = \max(c_i, d_j)$$

注意:这一步又体现了分治的常见用法是化多信息合并为二信息合并。固定i,哪些j会满足要求?

序列分治

Special Segments

CF1156E

给定一个数组,问有多少个
$$(i,j)$$
 满足 $a_i + a_j = \max_{k \in [i,j]} a_k$ 。 $n \le 10^5$

$$a_i + a_j = \max(c_i, d_j)$$

固定 i, 哪些 j 会满足要求?

 $c_i \geq d_j$, $c_i < d_j$ 的限制把j分成了 $j \leq p$, j > p 两端,p 可以随i 双指针。问题转化为:前缀/后缀 = x 的元素个数,可以双指针过程中维护 map。

序列分治

小结

前面的例题已经向我们展示了分治解决区间计数问题的范式:

- 1. 转为两个信息合并。
- 2. 对合并方式分类讨论,再分离变量,分别计算。这里,不要惧怕分类讨论繁复,毕竟"讨论"之难,怎样也不如"思维"之难。是谓:

胆大心细不畏繁, 勇刃难题换笑颜。

更多练习题: P4755

序列分治

最大独立集

P7482

给定一个序列, 求所有区间的最大独立集之和。

$$n \le 10^5$$

看题,便知可立刻写出最大独立集的二信息合并形式:

预处理出 l0, l1, r0, r1 分别表示左侧不选/选(这里,为了避免额外的取 max 操作,可以认为 1 表示选/不选均可)mid 的最大独立集,右侧不选/选 mid + 1 的最大独立集,则

$$ans(i,j) = max(l1_i + r0_j, l0_i + r1_j)$$

提示:分类讨论,分离变量。

序列分治

最大独立集

P7482

给定一个序列, 求所有区间的最大独立集之和。

$$n \le 10^5$$

$$ans(i,j) = max(l1_i + r0_j, l0_i + r1_j)$$

枚举i。

若 $l1_i + r0_j \ge l0_i + r1_j$,就是 $l1_i - l0_i \ge r1_j - r0_j$ 。要求所有这样的j的 $l1_i + r0_j$ 之和,也就是分别是个数、r0之和。提前把j按照r1 - r0排序,二分出分界点,维护前缀和即可;另一侧同理。

时间复杂度 $O(n \log^2 n)$ 。

偏序问题的定义

偏序问题, 是形态如下的问题:

偏序问题的一般形式

k 维空间里有n 个点,第i 个点的坐标为 $\left(x_{i,j}\right)$ 其中 $1 \leq j \leq k$ 。

有 q 次询问,每次询问包含一个点 (y_j) ,求出有多少个给出的点满足 $\forall 1 \leq j \leq k, x_{i,j} \leq y_i$ 。

有时,上述问题也简称"k维数点"。

偏序问题的定义

有时题目要求的不是点数,而是点的权值和/异或和或更为复杂的信息合并,维护方法没有本质区别。

需要注意, 偏序问题

- 1. 是"数点",不是数"点对"或其他。
- 2. 只能处理"每维分别小于(当然小于等于也可以)"的限制。

解决偏序问题的通法叫做 CDQ 分治,可以在 k-1 个 log 的时间复杂度内解决 k 维偏序。

偏序问题的例子

在具体学习 CDQ 分治的流程之前, 我们先看几个偏序问题的例子。事实上, 在省选及以前的阶段, OI 中的数据结构问题有很大一部分都用到了偏序问题的思想, 所以学习它是非常有用的。

- 1. 逆序对计数
 - 把 (i,a_i) 看成点,则每个i对应的j的数量是二维数点。
 - 注意:不是"逆序对"是二维数点,而是对于一个 i 数 j 是二维数点。
- 2. 矩形求和
 - 给出二维平面上的一些点,每次询问一个横平竖直的矩形,求出矩形内有几个点。
 - 拆分成前缀的和差。(由此也看出,如果不是前缀问题,则需要信息有可减性)

区间数颜色

P4113

给出一个序列,多次询问区间中有几种不同的 a_i 。

$$n, q \leq 10^6$$

记 lst_i 表示 a_i 上次 (j < i) 出现的位置。

则区间内 a_i 的种数就是 $j \in [l,r]$, $lst_j < l$ 的个数,因为此时每种 a_i 仅在第一次出现时有贡献。

带修数点

经典问题

平面上初始没有点, 你需要支持动态加点、删点, 同时求矩形内点数。

$$n, q \leq 10^5$$

加入时间维t, 在点出现时视为点(x,y,t), 权值为1; 消失时权值为-1。

询问的时间为t',就是求t < t'的所有点的权值和。

三角形求和

经典问题

给定平面上n个点,每次询问给出u,v,w,求满足 $x+y \le u,x \ge v,y \ge w$ 的点的个数。

$$n, q \leq 10^6$$

画图可知,可以拆分为三个区域的和、差,其中每个区域都只有两维限制。因此,本题实际上是二维偏序。

小结

前几个偏序问题的应用中,有几个需要注意的地方:

- 1. 对于"出现几次"或类似的问题,考虑 lst。
- 2. 带修问题就是加时间维。
- 3. 并不是把问题转化为偏序问题就万事大吉了,有时候如果发现的性质太少,偏序问题维数过高,反而可能阻碍问题的继续思考。

二维偏序

扫描线

二维偏序是最简单的偏序问题, 通常采用扫描线来解决。

想象一根竖着的数轴扫过平面,在扫到x=i时,数轴的j位置就存储了(i,j)位置的信息。

放在区间上,扫描线可以理解成:枚举r,同时维护一个数据结构,在扫到 $r=r_0$ 时,数据结构的l位置存储 $[l,r_0]$ 的区间信息。

扫描线解决二维偏序的方法是:按x从小到大考虑点和询问,用数据结构维护y一维。可以结合平面上矩形数点来理解。

矩形面积并

经典问题

平面上有 n 个矩形, 求其面积并。

$$n \le 10^5$$
, x_i , $y_i \le 10^9$

首先离散化。注意:此处离散化需要保留权值。

对x一维扫描线,对y一维维护线段树。在扫到x = k(实际上对应了离散化数组里的 $v_k \sim v_{k+1}$ 这一段)时,希望在线段树上u 位置处维护出 (k,u) 的覆盖情况。

维护方法是:对于矩形 (x_0, y_0, x_1, y_1) ,在 x_0 处给 $[y_0, y_1]$ 加一(注意 离散化后是个左闭右开区间),在 x_1+1 处减一。询问即为 ≥ 1 的位置个数。

扫描线

矩形面积并

经典问题

平面上有 n 个矩形, 求其面积并。

 $n \le 3 \times 10^5$

≥1的位置个数可以转化为=0的位置个数。

此时有技巧:注意到覆盖次数总是≥0,所以只需维护最小值个数(由于离散化,其实维护的是最小值对应的区间长度和)。

扫描线

连续段问题

CF526F

给定一个排列,问有几个区间满足 $r-l=\max_{i\in[l,r]}a_i-\min_{i\in[l,r]}a_i$ 。

$$n \le 3 \times 10^5$$

枚举r, 计算有多少个l满足 $r-l=\max_{i\in[l,r]}a_i-\min_{i\in[l,r]}a_i$ 。我们希望在线段书上维护出答案。

提示: 先不管计数问题, 怎么维护 $\max_{i \in [l,r]} a_i - \min_{i \in [l,r]} a_i$? 也就是, 希望在 r 处时, 线段树上 l 位置上恰好等于 $\max_{i \in [l,r]} a_i - \min_{i \in [l,r]} a_i$ 。

扫描线

连续段问题

CF526F

给定一个排列,问有几个区间满足 $r-l=\max_{i\in[l,r]}a_i-\min_{i\in[l,r]}a_i$ 。

$$n \le 3 \times 10^5$$

希望在 r 处时,线段树上 l 位置上恰好等于 $\max_{i \in [l,r]} a_i - \min_{i \in [l,r]} a_i$ 。

从 $\max_{i \in [l,r]} a_i$ 到 $\max_{i \in [l,r+1]} a_i$ 的变化不就是单调栈所求吗! 在弹栈的时候顺便执行一下线段树区间加(区间为 $(st_{top-1},st_{top}]$)操作就行了。

同理, $\max_{i \in [l,r]} a_i - \min_{i \in [l,r]} a_i - (r-l)$ 这个整体也是好维护的,但如何计数?

扫描线

连续段问题

CF526F

给定一个排列,问有几个区间满足 $r-l=\max_{i\in[l,r]}a_i-\min_{i\in[l,r]}a_i$ 。

$$n \le 3 \times 10^5$$

提示: "区间 0 的个数"难以维护,但回想之前所学,什么值的个数容易维护? 类比"矩形面积并"问题。

注意到 $\max_{i \in [l,r]} a_i - \min_{i \in [l,r]} a_i - (r-l) \ge 0$,因此可以维护区间最小值个数。

高维偏序

CDQ分治

CDQ 分治的目的是,将 k 维偏序问题转化为 k-1 维偏序问题。当 k=2 时,就可以用扫描线解决了。

对第一维进行类似序列分治的分治。不妨假设询问的是 $x_i < x,...$ 的点数,则点 x_i 对于询问 x 的贡献在 $[x_i, x]$ 这个区间跨过 mid 时计算。

可以总结为: CDQ 分治特指考虑左侧对右侧的影响的分治。

在偏序问题上,分治第一维后,第一维的限制不复存在,也就把问题转为了总大小乘了 $\log i k - 1$ 维偏序问题。

高维偏序

讨论

CDQ分治思想简单,但当维数 ≥ 4 时就又难写又慢了。各位在准备写高维偏序代码前,一定要多想能不能多发现一些能够降维的性质。(例如:若 a 有单调性,则 $i \leq p$ 和 $a_i \leq q$ 是同一维限制!)

如果信息不可减, 偏序问题什么时候仍然可做?

至多只有一维不是前缀/后缀限制

如何正确地排序

P8253

有一个
$$4 \times n$$
 的数组 $a_{i,j}$,定义
$$f(i,j) = \min_{k} (a_{k,i} + a_{k,j}) + \max_{k} (a_{k,i} + a_{k,j})$$
 求 $\sum_{i,j \in [1,n]} f(i,j)$ 。

$$n \le 2 \times 10^5$$

分开处理 min 和 max。

讨论 min 和 max 分别在哪里取到,再分离变量,就是三维偏序问题。需要注意相等时不要算重:可以认为 k 更小的值更小。

更多练习题: P4169, P3157, P2487

小结

我们刚刚学习了偏序问题的解法,特别地,学习了扫描线解决问题的思路。其中有以下要点值得注意:

- 1. 将"求0的个数"转为求"区间最小值个数"。
- 2. 对于有 max min 的式子,分类讨论在哪里取到再分离变量是常见处理方法。

天天爱打卡

P9871

小丁跑步打卡。共有n天,每天可以跑步或不跑步。能量值初始为0,若某天选择跑步,则能量值减少d。不能连续超过k天跑步。

有m条奖励:若他在第 $l_i \sim r_i$ 天都选择跑步,会得到 v_i 能量值。

问n天后能量值最高是多少。

$$n \le 10^9, m \le 10^5$$

先对l,r离散化。思考:具体如何离散化?

天天爱打卡

P9871

选择跑步,则能量值减少d。不能连续超过k 天跑步。有m 条奖励:若他在第 $l_i \sim r_i$ 天都选择跑步,会得到 v_i 能量值。

以 l_i, r_i 划分数轴(均为闭区间),则跑步一定是一段一段跑。

设 dp; 表示第 1~ i 段的最优决策下能量值最大值,如何转移?

提示: 枚举最后一段跑步的连续段。

若不跑, $dp_{i-1} \to dp_i$ 。 若跑,枚举 $j \le i$, $dp_{j-2} - d(s_i - s_{j-1}) + V(j,i) \to dp_i$ 。这里要求 $s_i - s_{j-1} \le k$,可以二分求出分界点。

天天爱打卡

P9871

选择跑步,则能量值减少d。不能连续超过k天跑步。有m条奖励:若他在第 $l_i \sim r_i$ 天都选择跑步,会得到 v_i 能量值。

若不跑, $dp_{i-1} \to dp_i$ 。 若跑,枚举 $j \le i$, $dp_{j-2} - d(s_i - s_{j-1}) + V(j,i) \to dp_i$ 。

用扫描线的思想,在 r_i 处给 $j \leq l_i$ 的j加上 v_i 的贡献,则上述转移就是区间最大值。

时间复杂度 $O(m \log m)$ 。 更多类似题目: P2605, CF1889C2

小结

时间所限,今天只为大家展示了一道数据结构用于优化具体算法的例子,也就是去年联赛的最后一题。

如果你会设计简单的序列 dp, 掌握了扫描线的思想, 也能正确处理离散化的细节, 这题对你来说应当是容易的。

用数据结构优化其它算法时,以下法则应当牢记于心:

想清楚数据结构中存储的数据的含义。 时间?下标?存储内容?合并方式? 我想求的答案满不满足我想用的数据结构的要求?